

Lucas Rover  
Universidade Tecnológica Federal do Paraná (UTFPR)  
Ponta Grossa, Paraná, Brasil

February 28, 2026

Aos Editores  
*Nature Machine Intelligence*

Prezados Editores,

Submetemos **“Same Prompt, Different Answer: Exposing the Reproducibility Illusion in Large Language Model APIs”** para consideração como Artigo na *Nature Machine Intelligence*.

Mais de 1,5 bilhão de pessoas interagem semanalmente com grandes modelos de linguagem por meio de APIs comerciais. Somente o ChatGPT atende mais de 800 milhões de usuários semanais, o Gemini ultrapassa 750 milhões mensais e o Claude alcança 19 milhões com crescimento anual de 190%. Todo grande provedor de API oferece um parâmetro de temperatura que, quando definido como zero, é documentado como produzindo saídas determinísticas. Pesquisadores de medicina, engenharia, ciências ambientais e análise de dados dependem dessa garantia sempre que reportam resultados gerados por LLMs. Nosso manuscrito mostra que essa garantia não se sustenta.

Conduzimos 4.104 experimentos controlados com oito modelos e cinco provedores de API. Sob decodificação gulosa com temperatura zero e sementes aleatórias fixas, modelos implantados localmente reproduziram suas próprias saídas 96% das vezes, enquanto modelos servidos por API alcançaram apenas 22%. A diferença supera quatro vezes, e é invisível aos usuários: as saídas permanecem semanticamente equivalentes (BERTScore F1 > 0,97), mas diferem textualmente, de modo que um pesquisador lendo duas respostas lado a lado não perceberia a variação. Um experimento de quase-isolamento, no qual os mesmos pesos do modelo foram servidos por um provedor em nuvem com infraestrutura mínima, recuperou reprodutibilidade próxima à local, atribuindo a variação à complexidade da infraestrutura de produção (paralelismo de tensores, batching dinâmico, decodificação especulativa) e não à implantação em nuvem em si. Complementamos esse diagnóstico com um protocolo leve de proveniência que adiciona menos de 1% de sobrecarga computacional e torna a variação oculta detectável.

Trabalhos anteriores abordaram esse problema apenas parcialmente. Atil et al. (2024) testaram o ChatGPT isoladamente; Yuan et al. (NeurIPS 2025) focaram na precisão numérica de um único provedor. Nosso estudo é o primeiro a abranger cinco provedores e três implantações locais, estender a análise a fluxos multi-turno e de geração aumentada por recuperação (RAG), e entregar tanto atribuição causal quanto uma ferramenta de mitigação pronta para uso, tudo validado com intervalos de confiança bootstrap de 10.000 reamostras e correção de Holm–Bonferroni em 68 testes. Várias de nossas referências são preprints, refletindo um campo onde estudos fundamentais sobre o comportamento de inferência de LLMs estão apenas começando a surgir;

nossa contribuição fundamenta essas observações com o rigor estatístico que a pesquisa confiável em IA demanda.

Acreditamos que este trabalho se alinha fortemente com o engajamento contínuo da *Nature Machine Intelligence* com a confiabilidade de LLMs. Kumar et al. examinaram recentemente quando LLMs podem ser confiáveis como avaliadores (*Nat. Mach. Intell.* **8**, 173–185, 2026), e Ciriello chamou atenção para o preocupante aumento da suspeição sobre IA generativa em publicações acadêmicas (*Nat. Mach. Intell.*, 2026, [doi:10.1038/s42256-026-01178-z](https://doi.org/10.1038/s42256-026-01178-z)). Seus editoriais têm pedido transparência em frameworks de LLM (2024) e sistemas multiagente (2026). Nossos achados falam diretamente a essas preocupações: se as saídas dos modelos mais amplamente utilizados em pesquisa não podem ser reproduzidas, a credibilidade de todo estudo derivado está em risco.

Após a aceitação, depositaremos o protocolo completo e todos os 4.104 registros experimentais no Protocol Exchange e disponibilizaremos o repositório GitHub (<https://github.com/Roverlucas/genai-reproducibility-pro>) sob licenças abertas (MIT para código, CC-BY 4.0 para dados). Este manuscrito não foi publicado em outro local e não está sob consideração de nenhum outro periódico. Todos os autores aprovaram a submissão.

Atenciosamente,

Lucas Rover  
Programa de Pós-Graduação em  
Engenharia Mecânica  
Universidade Tecnológica Federal do  
Paraná (UTFPR)  
Ponta Grossa, Paraná, Brasil

*Em nome de todos os autores:*

[lucasrover@utfpr.edu.br](mailto:lucasrover@utfpr.edu.br)  
Lucas Rover, Eduardo Tadeu Bacalhau, Anibal Tavares de Azevedo e Yara de Souza Tadano